

4.10 다변량 회귀분석 - 수학적 모델

- ◆ 입력에 사용되는 특징이 하나가 아니라 n 개라면 선형 회귀 모델은 다음과 같은 식으로 표현할 수 있으며 **다변량**multivariate 회귀분석이라 함

$$\hat{y} = w_1x_1 + w_2x_2 + \cdots + w_nx_n + b$$

$$\hat{y} = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix} \quad X = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \cdots & x_n^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \cdots & x_n^{(2)} \\ 1 & x_1^{(3)} & x_2^{(3)} & \cdots & x_n^{(3)} \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} & \cdots & x_n^{(m)} \end{bmatrix} \quad w = \begin{bmatrix} b \\ w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix}$$


$$\hat{y} = XW$$

머신러닝

1

사람들의 식사량과 운동량에 따른 건강 위험도(건강검진 결과) 관계 분석

- ◆ 식사량과 운동량이 기록된 사람들에게 대해 건강검진을 통해 건강위험도 정보를 측정할 수 있었다면 아래 그림 왼쪽과 같이 운동량과 식사량에 따라 건강위험도가 결정되는 어떤 관계가 있을 것이라고 추측
- ◆ 이때 이 관계가 선형 관계라는 가설을 세웠다면 선형 회귀는 **이 데이터를 설명할 수 있는 평면**을 찾는 것



머신러닝

2

- ◆ 수식으로 표현하면 식사량을 x_1 , 운동량을 x_2 라고 할 수 있고, 위험도 y 가 다음과 같은 식으로 설명될 수 있다는 것

$$\hat{y} = w_1 x_1 + w_2 x_2 + b = [x_1 \ x_2] \begin{bmatrix} w_1 \\ w_2 \end{bmatrix} + b$$

- ◆ 이것을 m개의 데이터로 표현하면...

$$X = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} \\ x_1^{(2)} & x_2^{(2)} \\ \vdots & \vdots \\ x_1^{(m)} & x_2^{(m)} \end{bmatrix} \quad W = \begin{bmatrix} w_1 \\ w_2 \end{bmatrix} \quad Y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}$$

$$b = b$$

$$Y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix} = X \cdot W + b = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & \dots & x_n^{(1)} \\ x_1^{(2)} & x_2^{(2)} & \dots & x_n^{(2)} \\ x_1^{(3)} & x_2^{(3)} & \dots & x_n^{(3)} \\ \vdots & \vdots & \dots & \vdots \\ x_1^{(m)} & x_2^{(m)} & \dots & x_n^{(m)} \end{bmatrix} \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix} + b$$

머신러닝

3

- ◆ 수식으로 표현하면 식사량을 x_1 , 운동량을 x_2 라고 할 수 있고, 위험도 y 가 다음과 같은 식으로 설명될 수 있다는 것

$$\hat{y} = w_1 x_1 + w_2 x_2 + b = [x_1 \ x_2 \ 1] \begin{bmatrix} w_1 \\ w_2 \\ b \end{bmatrix}$$

- ◆ 이것을 m개의 데이터로 표현하면...

$$X = \begin{bmatrix} x_1^{(1)} & x_2^{(1)} & 1 \\ x_1^{(2)} & x_2^{(2)} & 1 \\ \vdots & \vdots & \vdots \\ x_1^{(m)} & x_2^{(m)} & 1 \end{bmatrix} \quad W = \begin{bmatrix} w_1 \\ w_2 \\ b \end{bmatrix} \quad Y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}$$

w_0

$$Y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ y^{(3)} \\ \vdots \\ y^{(m)} \end{bmatrix} = X \cdot W = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \dots & x_n^{(2)} \\ 1 & x_1^{(3)} & x_2^{(3)} & \dots & x_n^{(3)} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} & \dots & x_n^{(m)} \end{bmatrix} \begin{bmatrix} w_0 \\ w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix}$$

머신러닝

4

- ◆ 수식으로 표현하면 식사량을 x_1 , 운동량을 x_2 라고 할 수 있고, 위험도 y 가 다음과 같은 식으로 설명될 수 있다는 것

$$\hat{y} = w_1x_1 + w_2x_2 + b = \mathbf{w}^T \mathbf{x} + b$$

$$\hat{y} = w_1x_1 + w_2x_2 + b = [w_1 \ w_2 \ b] \begin{bmatrix} x_1 \\ x_2 \\ 1 \end{bmatrix}$$

- ◆ 이때 w 는 w_1, w_2 를 원소로 하는 벡터이고, x 는 입력 특징 x_1, x_2 를 원소로 하는 벡터
- ◆ 다변량 회귀분석은 이때 특징 벡터 x 가 임의의 차원을 가질 수 있는 것을 의미하며, 찾아야 하는 것은 n 차원 공간의 초평면(hyperplane)이 되는 것

머신러닝

5

- ◆ 이것을 **파라미터parameter 벡터**로 표현할 수도 있음
 - 이 모델의 동작을 결정하는 변수는 w 와 b
 - 이 둘을 따로 구분하지 않고 하나의 파라미터 벡터 θ 로 표현한다면 w_i 는 θ_i 로 표현할 수 있고, b 는 θ_0 라고 하면 될 것 (여기서 $x_0 = 1$)
 - 그러면 선형 회귀는 다음과 같은 식으로 표현할 수 있음

$$\hat{y} = \theta_0x_0 + \theta_1x_1 + \theta_2x_2 + \cdots + \theta_nx_n = X\theta$$

- 따라서 선형 회귀분석의 가설 $y = ax + b$ 는 아래와 같이 간략히 표현할 수 있다.

$$Y = X\theta \quad \text{또는} \quad Y = XW$$

- 다변량 회귀분석은 이 때 특징 벡터 x 가 임의의 차원을 가질 수 있는 것을 의미하며, 찾아야 하는 것은 n 차원 공간의 초평면(hypoerplane)이 되는 것

머신러닝

6

- ◆ 데이터의 인스턴스의 개수가 m 이라고 하면 i 번째 인스턴스는 $x^{(i)}$ 으로 나타낼 수 있고, $n + 1$ 개의 원소를 가진 다음과 같은 벡터로 표현할 수 있다. 이 데이터 인스턴스에 대응하는 레이블이 $y^{(i)}$ 이다

$$x^{(i)} = (1, x_1^{(i)}, x_2^{(i)}, x_3^{(i)}, \dots, x_n^{(i)})$$

$$\begin{aligned} x^{(1)} &= (1, x_1^{(1)}, x_2^{(1)}, x_3^{(1)}, \dots, x_n^{(1)}) \\ x^{(2)} &= (1, x_1^{(2)}, x_2^{(2)}, x_3^{(2)}, \dots, x_n^{(2)}) \\ &\dots \\ x^{(m)} &= (1, x_1^{(m)}, x_2^{(m)}, x_3^{(m)}, \dots, x_n^{(m)}) \end{aligned}$$

$$X = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \dots & x_n^{(2)} \\ 1 & x_1^{(3)} & x_2^{(3)} & \dots & x_n^{(3)} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} & \dots & x_n^{(m)} \end{bmatrix}$$

머신러닝

7

$$X = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \dots & x_n^{(2)} \\ 1 & x_1^{(3)} & x_2^{(3)} & \dots & x_n^{(3)} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} & \dots & x_n^{(m)} \end{bmatrix}, \quad Y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ y^{(3)} \\ \vdots \\ y^{(m)} \end{bmatrix}, \quad \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix}$$

$$Y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ y^{(3)} \\ \vdots \\ y^{(m)} \end{bmatrix} = X \cdot \theta = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \dots & x_n^{(2)} \\ 1 & x_1^{(3)} & x_2^{(3)} & \dots & x_n^{(3)} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} & \dots & x_n^{(m)} \end{bmatrix} \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix}$$

$$y^{(1)} = 1 \cdot \theta_0 + x_1^{(1)} \theta_1 + x_2^{(1)} \theta_2 + \dots + x_n^{(1)} \theta_n$$

$$y^{(2)} = 1 \cdot \theta_0 + x_1^{(2)} \theta_1 + x_2^{(2)} \theta_2 + \dots + x_n^{(2)} \theta_n$$

...

$$y^{(m)} = 1 \cdot \theta_0 + x_1^{(m)} \theta_1 + x_2^{(m)} \theta_2 + \dots + x_n^{(m)} \theta_n$$

머신러닝

8

행렬 표현으로 바꾸기($Y=WX+b$)

- 3개의 분류기를 하나의 수식으로 묶어서 간단하게 표현
> w들을 열벡터로 표현해 class 수 x 특징 차원 수 행렬로 표현 (3x2 행렬)

$$\begin{aligned}
 \begin{bmatrix} w_{a1} & w_{a2} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + b_a &= w_{a1}x_1 + w_{a2}x_2 + b_a \\
 \begin{bmatrix} w_{b1} & w_{b2} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + b_b &= w_{b1}x_1 + w_{b2}x_2 + b_b \\
 \begin{bmatrix} w_{c1} & w_{c2} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + b_c &= w_{c1}x_1 + w_{c2}x_2 + b_c
 \end{aligned}$$

↓

$$\begin{bmatrix} w_{a1} & w_{a2} \\ w_{b1} & w_{b2} \\ w_{c1} & w_{c2} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} b_a \\ b_b \\ b_c \end{bmatrix} = \begin{bmatrix} w_{a1}x_1 + w_{a2}x_2 + b_a \\ w_{b1}x_1 + w_{b2}x_2 + b_b \\ w_{c1}x_1 + w_{c2}x_2 + b_c \end{bmatrix}$$

행렬 표현으로 바꾸기($Y=WX+b$)

- 클래스 3, 데이터 4개인 경우 → 데이터를 열벡터로 표기
- 효과적인 행렬 연산을 위해 X와 W에 대한 곱셈 위치 변경

$$\begin{bmatrix} w_{a1} & w_{a2} \\ w_{b1} & w_{b2} \\ w_{c1} & w_{c2} \end{bmatrix} \begin{bmatrix} x_{11} & x_{21} & x_{31} & x_{41} \\ x_{12} & x_{22} & x_{32} & x_{42} \end{bmatrix} + \begin{bmatrix} b_1 & b_1 & b_1 & b_1 \\ b_2 & b_2 & b_2 & b_2 \\ b_3 & b_3 & b_3 & b_3 \end{bmatrix}$$

$$\text{shape : } [3 \times 2] \times [2 \times 4] + [3 \times 4] = [3 \times 4]$$

$$= \begin{bmatrix} x_{11}w_{a1} + x_{12}w_{a1} + b_1 & x_{21}w_{a1} + x_{22}w_{a1} + b_1 & x_{31}w_{a1} + x_{32}w_{a1} + b_1 & x_{41}w_{a1} + x_{42}w_{a1} + b_1 \\ x_{11}w_{b1} + x_{12}w_{b2} + b_2 & x_{21}w_{b1} + x_{22}w_{b2} + b_2 & x_{31}w_{b1} + x_{32}w_{b2} + b_2 & x_{41}w_{b1} + x_{42}w_{b2} + b_2 \\ x_{11}w_{c1} + x_{12}w_{c2} + b_3 & x_{21}w_{c1} + x_{22}w_{c2} + b_3 & x_{31}w_{c1} + x_{32}w_{c2} + b_3 & x_{41}w_{c1} + x_{42}w_{c2} + b_3 \end{bmatrix}$$

행렬 표현으로 바꾸기($Y=XW+b$)

- 클래스 3, 데이터 4개인 경우 → 데이터를 행벡터로 표기
- 열벡터로 정의된 w 는 샘플 수에 따라서 행렬의 크기가 변화되지 않고 고정됨

$$\begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ x_{31} & x_{32} \\ x_{41} & x_{42} \end{bmatrix} \begin{bmatrix} w_{a_1} & w_{b_1} & w_{c_1} \\ w_{a_2} & w_{b_2} & w_{c_2} \end{bmatrix} + \begin{bmatrix} b_1 & b_2 & b_3 \\ b_1 & b_2 & b_3 \\ b_1 & b_2 & b_3 \\ b_1 & b_2 & b_3 \end{bmatrix}$$

$$[4 \times 2] \times [2 \times 3] + [4 \times 3] = [4 \times 3]$$

$$= \begin{bmatrix} x_{11}w_{a_1} + x_{12}w_{a_2} + b_1 & x_{11}w_{b_1} + x_{12}w_{b_2} + b_2 & x_{11}w_{c_1} + x_{12}w_{c_2} + b_3 \\ x_{21}w_{a_1} + x_{22}w_{a_2} + b_1 & x_{21}w_{b_1} + x_{22}w_{b_2} + b_2 & x_{21}w_{c_1} + x_{22}w_{c_2} + b_3 \\ x_{31}w_{a_1} + x_{32}w_{a_2} + b_1 & x_{31}w_{b_1} + x_{32}w_{b_2} + b_2 & x_{31}w_{c_1} + x_{32}w_{c_2} + b_3 \\ x_{41}w_{a_1} + x_{42}w_{a_2} + b_1 & x_{41}w_{b_1} + x_{42}w_{b_2} + b_2 & x_{41}w_{c_1} + x_{42}w_{c_2} + b_3 \end{bmatrix}$$

머신러닝(선형회귀)를 통해 하고자 하는 일은 아래의 가설에서 W 값을 찾는 일이며

$$Y = XW$$

$$y_hat = np.matmul(X, W)$$

여기서 가설을 $H(X)$ 라고 표현한다면 아래와 같이 쓸 수 있고...

$$H(X) = XW$$

$$hypothesis = np.dot(X, W)$$

가설을 평가하기 위한 Cost 함수를 오차제곱평균(Mean Squared Error)로 사용할 경우 아래와 같이 정의할 수 있다.

$$MSE(W) = \frac{1}{m} \sum_{i=1}^m (x^{(i)}W - y^{(i)})^2$$

$$= mean\{(XW - y)^2\}$$

$$mse = ((y_hat - y)**2).mean()$$

- ◆ 가설은 파라미터 θ 에 의해 동작이 결정되므로, m 개의 데이터 인스턴스에 대해 현재 가설의 **평균 제곱 오차**(mean squared error)를 다음과 같이 구할 수 있음

- 각 데이터 인스턴스에 대해 구한 오차를 제곱하여 평균한 값
- 다변량 선형 회귀 분석은 결국 이 오차가 최소가 되는 파라미터 θ 를 찾는 문제

$$E_{mse}(\theta) = \frac{1}{m} \sum_{i=1}^m (x^{(i)}\theta - y^{(i)})^2$$

4.11 회귀분석의 학습, 혹은 최적화 방법 - 정규 방정식

- ◆ 다변량 선형 회귀에서 가설과 레이블의 평균 제곱 오차를 구했다면, 오차를 줄이는 방향으로 파라미터를 수정하는 것이 학습
- 특정 파라미터 θ_j 에 대해 이 오차를 편미분하면 다음을 얻을 수 있음.

$$\frac{\partial E_{mse}(\theta)}{\partial \theta_j} = \frac{2}{m} \sum_{i=1}^m (x^{(i)}\theta - y^{(i)})x_j^{(i)}$$

$$X = \begin{bmatrix} 1 & x_1^{(1)} & x_2^{(1)} & \dots & x_n^{(1)} \\ 1 & x_1^{(2)} & x_2^{(2)} & \dots & x_n^{(2)} \\ 1 & x_1^{(3)} & x_2^{(3)} & \dots & x_n^{(3)} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & x_1^{(m)} & x_2^{(m)} & \dots & x_n^{(m)} \end{bmatrix} \quad \theta = \begin{bmatrix} \theta_0 \\ \theta_1 \\ \theta_2 \\ \vdots \\ \theta_n \end{bmatrix} \quad Y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ y^{(3)} \\ \vdots \\ y^{(m)} \end{bmatrix}$$

- ◆ 오차 곡면이 파라미터에 대해 가지는 기울기 $\nabla_{\theta} E_{mse}$ 의 j 번째 원소가 됨
- 파라미터는 다음과 같이 변경할 수 있음

$$\theta \leftarrow \theta - \eta \nabla_{\theta} E_{mse}$$